# 林宇軒

## Machine Learning for Quantitative Research

以金融資料與機器學習進行台股量化研究，範圍涵蓋橫截面選股、日內逐筆成交與五檔模型，以及資料品質與交易可行性驗證。

**台股機器學習**

歷史排序訊號為正；h22（預測未來 22 個交易日）/ 10 億元固定切分正式評估期呈現可重現的正向相對績效。以 T+1 次一交易日調整後開盤價成交的敏感度測試仍為正，但資金、交易單位與基準定義會影響結果。

**日內 Tick 機器學習**

模型呈現部分樣本外預測力；高信心做空分支為正向點估，但目前樣本與統計證據仍不足。

**金融資料品質**

以公開資訊觀測站、臺灣證券交易所與櫃位規則定位問題，部分案例獲確認與修正。

> **Python · LightGBM · PyTorch · SHAP · 滾動驗證 · 回測**

GitHub: https://github.com/sean33885566/quant-ml-research
作品集： https://github.com/sean33885566/quant-portfolio

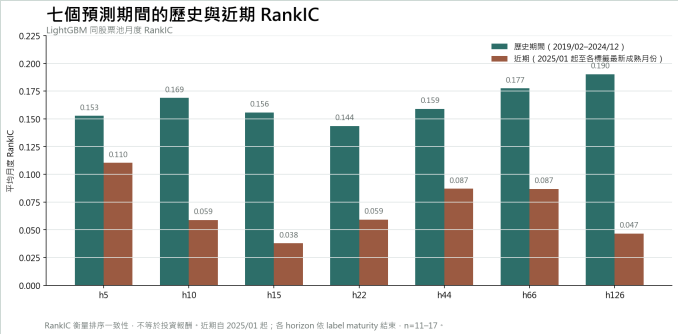
# h22 固定切分：可重現的歷史正式期相對績效

## 問題

台股價量、財務與籌碼資料能否排序未來表現較好的股票，並轉換成有研究價值的投資組合？

## 方法

- LightGBM 橫截面預測
- 7 個預測期間：未來 5～126 個交易日
- 滾動 / walk-forward 驗證
- 成本、流動性與基準回放




近期自 2025/01 起；各預測期間依未來報酬標籤成熟時間結束於最新成熟月份，n=11–17。

## 訊號與期間

- 2019/02–2024/12 RankIC 約 0.144–0.190
- 2019/02–2022/12 為投組規則選擇期
- 2023/01–2026/03 為正式評估期

| h22 固定切分正式期結果 | 年化報酬 | 相對基準資訊比率 |
|---|---|---|
| 策略 · 10 億元 · 2023/01–2026/03 | 35.30% | 1.326 |
| 原研究基準 | 31.95% | — |

**成交時點敏感度：**使用同一組固定投組權重，以 T+1 次一交易日調整後開盤價成交；10 億元整張版本 Active IR 為 +0.588。2019/02–2022/12 為投組規則選擇期；此結果不是實務 0050 帳戶或實盤驗證。

# 日內逐筆成交與五檔：從特徵工程到事件帳戶驗證

模型呈現部分樣本外預測訊號；高信心做空分支仍需更多資料驗證。

### 問題

逐筆成交（Tick）與五檔委託簿中的短期訊號，能否在實際時間與成交條件下形成有效預測？

### 資料範圍

**112 個交易日**

**每分鐘決策**

**主要持有 15 分鐘**

**Tick 與五檔委託簿**

### 模型與特徵

- LightGBM 回歸 / 三分類
- 多檔委託簿與微價格
- 成交強度、流動性與恢復代理指標
- 同步橫截面狀態

## 最終驗證設計

| 決策當下可交易股票 | 前一交易日流動性 | 樣本外門檻校準 | 訊號後下一可成交時點 |
| --- | --- | --- | --- |
| 時間一致的股票池 | 僅使用決策前資訊 | 歷史已成熟樣本 / 各測試區段前置校準 | 五檔容量與事件帳戶 |

### 結果

- 回歸與三分類模型呈現部分樣本外預測證據；兩個三分類版本能辨識部分做多 / 觀望 / 做空差異，但轉換成交易動作並扣除成本後，交易效益仍未轉正。
- 高信心做空分支呈正向點估，共 98 筆交易 / 33 個出手日。
- 年化夏普比率 95% 信賴區間 `[-4.057, 2.876]`，仍跨越零。
- 112 個交易日已參與研究開發，仍需要全新後續資料驗證。

# 三類可重現金融資料問題，部分獲平台確認與修正

以公開資訊觀測站（MOPS）/ XBRL、臺灣證券交易所（TWSE）與欄位規則，將異常整理為可重現條件，再回報第三方台股金融資料平台。

### 財報歷史缺漏

**問題** 部分股票的歷史財報科目出現跨季缺漏，且僅檢查單一欄位不足以界定影響範圍。

**驗證** 逐筆對照 MOPS / XBRL 原始資料，確認公開財報存在而平台資料為空值。

**結果** 平台人員先確認問題；後續回覆稱已處理 2015Q1–2018Q4 的歷史回補。150 個科目、增加 6,027 列資料與 228,073 個非空值 均為平台回覆數字，不是本人獨立驗證結論。

### 法人欄位錯位

**問題** 少量法人交易列不符合買進股數減賣出股數等於買賣超股數的基本欄位關係。

**驗證** 針對指定股票 / 日期對照 TWSE 原始資料，重現正式資料表中欄位向後錯位的情況。

**結果** 平台自動支援系統後續重現資料差異，並回覆已完成修正 / 回補；平台自動支援系統的回覆保留其系統身份，並不表述為真人工程師確認。

### 不可能數值

**問題** 法人買進股數曾出現不可能的負值，另有 1227 / 2017-07-06 的特定歷史數值與官方來源不一致。

**驗證** 對照 TWSE 原始資料，分別驗證負值問題與 1227 特定日數值。

**結果** 平台真人後續確認相關歷史問題，並回覆已修正特定日期錯值及更新負值問題資料。

> **資料完整性 · 資料可得時點 · 合理值域檢查 · 跨欄位一致性**

# 從研究程式到可重現流程

### 研究工具

- Python / pandas / NumPy
- LightGBM / PyTorch / SHAP
- 研究產物版本與來源追蹤
- 訓練中斷續跑（checkpoint / resume）
- JSON 格式檢查與自動化測試

### 公開程式庫

```
quant-ml-research/
├─ src/quant_ml_research/
├─ tests/
├─ docs/
└─ scripts/publication_guard.py
```

公開版只使用合成資料；Ridge 是展示時間驗證控制的最小可執行基準模型（baseline），歷史研究主要使用 LightGBM。

> 作品集展示研究設計、時間驗證、回測與錯誤偵測能力，不宣稱已建立正式上線的 MLOps 或實盤交易系統。

# 背景、研究與連結

## 學歷

**國立高雄科技大學**
金融資訊研究所 碩士｜2022.09–2024.06

## 碩士論文

運用輕量梯度提升機與 SHAP 解析常見因子對報酬率之影響（2024）

## 工作經歷

**群益期貨 AI 科學處**
三等專員（AI工程師）｜2025.03–2025.10

## 競賽與證照

- 2023 金融科技競賽實作組｜第三名
- 高科盃 2023 程式交易競賽｜第三名
- AI CUP 2023 玉山信用卡冒用偵測｜33 / 394

## 連結

GitHub
https://github.com/sean33885566/quant-ml-research

作品集
https://github.com/sean33885566/quant-portfolio

Resume
104 應徵頁面提供