林宇軒

Machine Learning for Quantitative Research

金融資料、機器學習與量化研究。從資料可得時點、特徵工程與樣本外驗證，延伸到交易成本、流動性、執行假設與 benchmark 檢查。

01 **台股機器學習選股研究與回測** 7 個 horizon · 630 組模型結果

02 **日內 Tick 機器學習與回測驗證** 112 個交易日 · 事件帳戶驗證

03 **金融資料品質檢查與修正回報** 資料驗證 · 可重現回報

台股機器學習 — 資料、PIT 與驗證

- 以公告、上傳與交易時點決定特徵首次可用日，不以資料所屬期間代替可得日。
- 上市櫃狀態、交易限制與缺值狀態依當時可知資訊建立，避免使用事後完整股票池。
- 訓練資料只納入已成熟的未來報酬 label；validation 與 test 依時間順序隔離。
- 所有橫截面轉換、裁剪與校準只使用訓練期或前期已成熟資料。

PIT 資料可得性流程



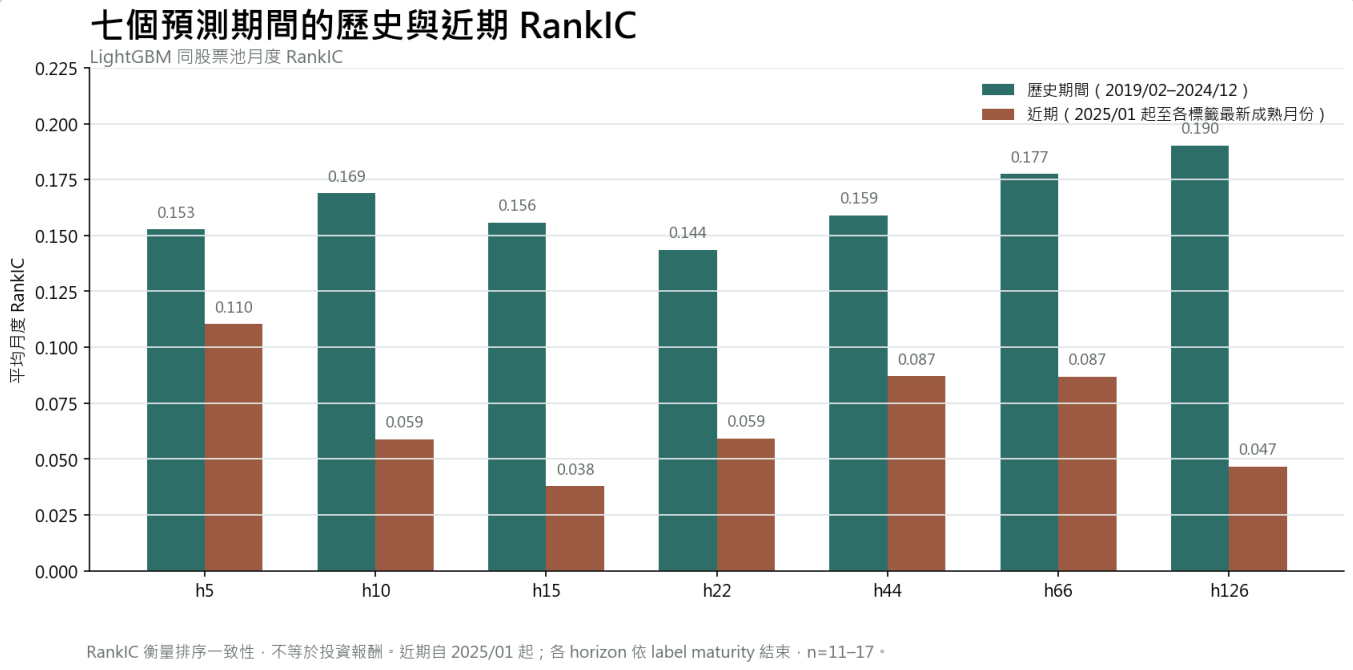
資料可得時點與模型實際輸入時點分開處理，避免尚未可得的資訊提前進入模型。

Walk-forward：先成熟、再訓練、最後才評估

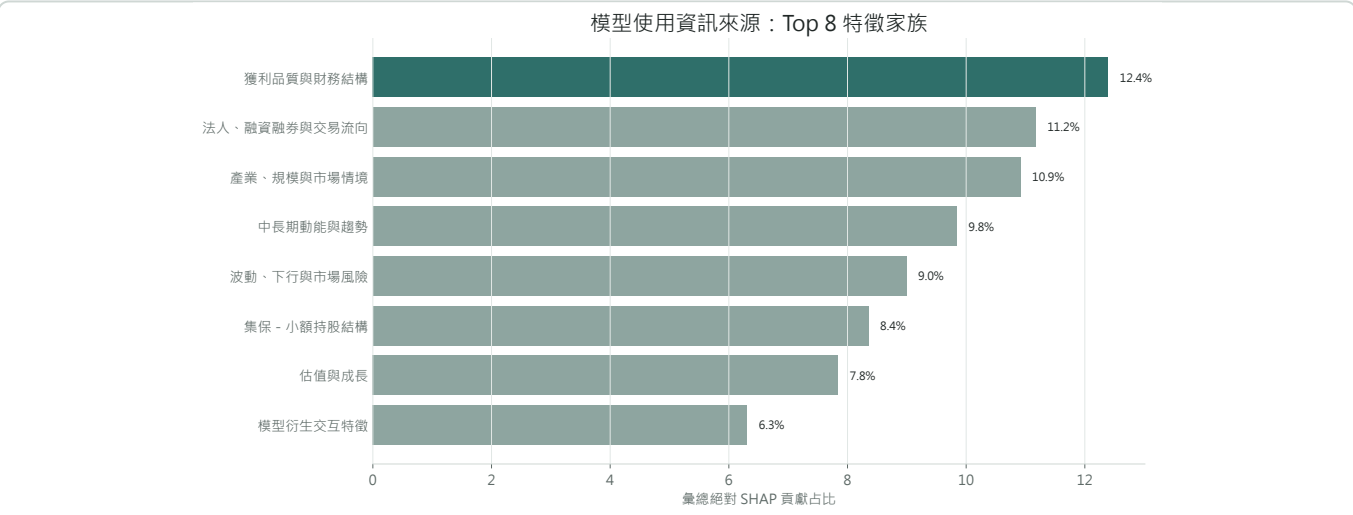


train、validation、label maturity gap 與 test 全程維持時間順序，不隨機打散。

台股機器學習 — RankIC 與 SHAP



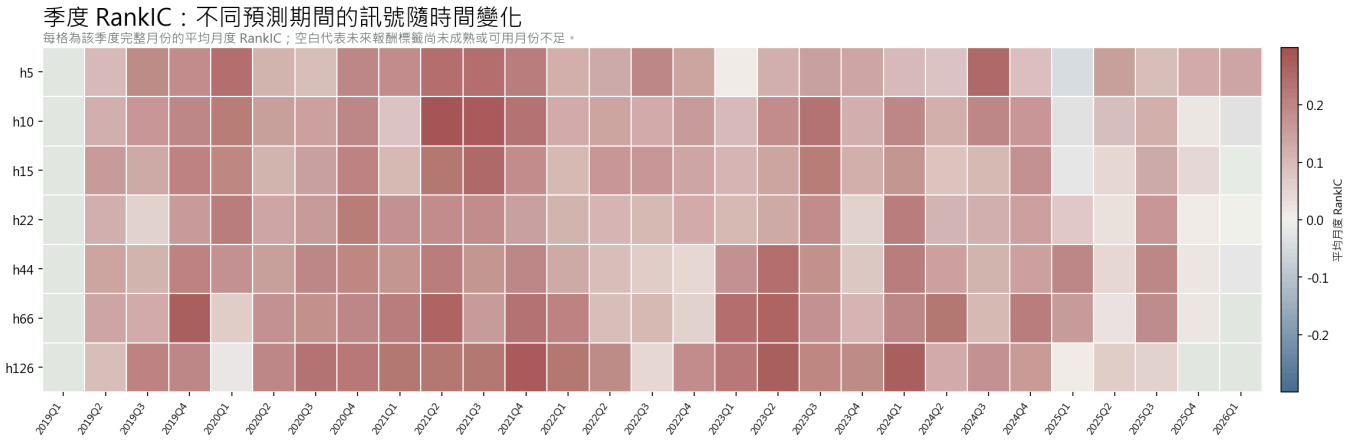
比較 2019/02–2024/12 與 2025/01 起的近期資料；各 horizon 因 label maturity 不同，近期可用月份為 11–17 個月。RankIC 衡量排序一致性，不是投資報酬率。



圖中為各特徵家族的彙總絕對 SHAP 貢獻占比，不代表特徵數量。

RankIC 的時間穩定性

季度 RankIC 顯示七個預測期間的訊號如何隨時間變化；這是排序穩定性診斷，不是投資報酬。



每格為完整季度三個月度 RankIC 的平均；灰色空白為未來報酬標籤尚未成熟或可用月份不足，不代表 RankIC = 0。

解讀邊界：近期多數預測期間較歷史期間偏弱，但仍有短期回升；本圖不支持所有預測期間同步永久失效，也不把任何事後月份當成事前結構轉折。

投組證據與實作條件敏感度

h22 固定切分正式期結果

研究口徑	策略年化報酬	原研究基準年化報酬	相對基準資訊比率
h22 · 10 億元 · 正式評估期 2023/01–2026/03	35.30%	31.95%	1.326

選擇期與正式期

2019/02–2022/12 為投組規則選擇期。選定固定的市值傾斜規則後，在 2023/01–2026/03 正式評估期檢查結果。固定投組權重與正式期指標均可由研究產物重現。

成交時點敏感度

使用同一組固定投組權重，以 T+1 次一交易日調整後開盤價成交，10 億元整張版本的 Active IR 為 **+0.588**。

實作條件解讀

- 正式期證據沿用原研究的訊號日調整後收盤價與原研究基準。
- T+1 僅為成交時點敏感度，不是實務 0050 帳戶或實盤驗證。
- 資金規模、交易單位與基準定義會明顯改變經濟結論。
- 本研究不宣稱已驗證可部署策略。

後續 h44 / 1 億元實務帳戶檢查保留在公開 Markdown 作為次要證據；其投組建構契約與 h22 固定切分結果不同。

日內逐筆成交與五檔：最終驗證流程與事件帳戶結果

112 個交易日 · 每分鐘決策 · 主要持有 15 分鐘 · 逐筆成交與五檔委託簿

資料與特徵

成交與價格、多檔委託簿、微價格、成交強度、流動性恢復代理指標與同步橫截面狀態。

模型設計

- R1（多 / 空雙回歸）：分別預測做多與做空的可成交淨報酬。
- C1（基礎特徵三分類）：預測做多 / 觀望 / 做空。
- C2（擴充市場微結構特徵三分類）：在基礎特徵外加入委託簿與市場微結構特徵。

驗證控制與成交語義

- 決策當下可交易股票與前一交易日流動性。
- 歷史已成熟樣本門檻 / fold 校準門檻。
- 訊號後下一可成交時點。
- 執行前最後可取得五檔；最晚 13:24 進入強制出場處理。

事件帳戶

五檔容量、現金、同時持倉、同股不重疊、整張交易及正常 / 強制出場。

帳戶結果

策略	交易數	出手日	淨損益（元）	年化夏普比率	95% 信賴區間
歷史已成熟樣本門檻 — 全部訊號	165	51	-12,566	-0.183	[-4.016, 2.141]
歷史已成熟樣本門檻 — 僅做空	98	33	+25,339	0.444	[-4.057, 2.876]
Fold 校準門檻 — 全部訊號	228	58	-81,264	-1.181	[-5.079, 1.573]
Fold 校準門檻 — 僅做空	121	43	-76,567	-1.234	[-5.505, 2.059]

統計不確定性與全新後續資料： 兩個三分類版本的成本後平均交易效益仍為負。歷史已成熟樣本門檻的僅做空分支呈正向點估，但只有 98 筆交易、33 個出手日；年化夏普比率的 5 日移動區塊 bootstrap 信賴區間跨零。112 個交易日已參與開發，尚待全新後續資料累積。

金融資料品質檢查與修正回報

在台股機器學習研究中辨識歷史財報缺漏、欄位錯位與不可能數值，透過公開來源、XBRL 與欄位規則交叉驗證後建立可重現回報。

案例一（DQ-01）· 財報歷史缺漏與 XBRL 回補

偵測 以股票 / 季度為單位檢查財報 資料完整性（coverage）、公告狀態與跨期缺值型態，整理最小可重現清單。

驗證 逐筆對照 公開資訊觀測站（MOPS）/ XBRL 原始資料，確認公開財報存在而平台資料為空值。

結果 平台人員先確認問題；後續回覆稱已處理 2015Q1–2018Q4 的歷史回補。150 個科目、增加 6,027 列資料與 228,073 個非空值均為平台回覆數字，不是本人獨立驗證結論。

案例二（DQ-02）· 買進 − 賣出 = 買賣超的跨欄位一致性

偵測 以全量 算術恆等式（arithmetic invariant）檢查 定位異常列，先排除單位、分類與調整項差異。

驗證 針對指定股票 / 日期對照 臺灣證券交易所（TWSE）原始資料，重現正式資料表中欄位向後錯位的情況。

結果 平台自動支援系統後續重現資料差異，並回覆已完成修正 / 回補；平台自動支援系統的回覆保留其系統身份，並不表述為真人工程師確認。

案例三（DQ-03）· 法人交易不可能負值與股票代號 1227 特定日錯值

偵測 以 合理值域限制（non-negative domain constraint） 掃描法人買進欄位，並保留特定股票 / 日期的可重現查詢。

驗證 對照 臺灣證券交易所（TWSE）原始資料，分別驗證負值問題與 股票代號 1227 特定日數值。

結果 平台人員後續確認相關歷史問題，並回覆已修正特定日期錯值及更新負值問題資料。

研究影響 資料完整性、資料可得時點、合理值域與跨欄位一致性檢查已納入後續研究流程。完整案例與佐證資料見作品集頁面。

GitHub 與研究範圍

公開程式庫

公開程式庫僅使用合成資料（synthetic data），包含資料可得時點 / 標籤成熟感知的資料切分、僅用訓練資料估計的轉換、簡化的成本感知投組邏輯、自動化測試（tests）與發布前檢查工具（publication guard）。

GitHub:
https://github.com/sean33885566/quant-ml-research

授權：目前未採用開源授權；公開內容保留著作權。

研究範圍

- 資料可得時點驗證（point-in-time）
- 滾動前推（walk-forward）機器學習
- 考量成交條件的投組研究
- 研究治理與可重現性

碩士論文（2024）：運用輕量梯度提升機與 SHAP 解析常見因子對報酬率之影響

> 作品集強調辨識未來資訊、區分預測證據與經濟證據，並如實呈現統計不確定性；不將正向點估直接轉述為可部署策略。